

Machine Learning Final Project

ANALISIS PREDIKSI MPG MOBIL



The Team



ANGGITA
SAKATO



KAYASMINE
ALIFIA GUNAWAN



MUHAMMAD
FARREL



CINTHYA



LUTHFI
HERIANDA



SYAHRUL
AKBAR



MUHAMMAD
AMAR PRIMUS



MUHAMMAD
AULIA



NABIL
NASHRULLAH



Our Case and Problem



Problem: to predict which car that have most efficient gallon/miles

Condition: 8 features of the car have correlation with the to gallon/milles

Goals: to give good recommendation to the buyer that suits their car needs

“

Data Understanding



- **Name:** Identifikasi unik untuk setiap mobil.
- **MPG:** Efisiensi bahan bakar yang diukur dalam mil per galon.
- **Cylinders:** Jumlah silinder pada mesin mobil.
- **Displacement:** Kapasitas atau ukuran mesin (cc), menunjukkan besar volume ruang bakar.
- **Horsepower:** Daya keluaran mesin mobil.
- **Weight:** Berat dari mobil tersebut.
- **Acceleration:** Kemampuan mobil untuk meningkatkan kecepatan, diukur dalam detik.
- **Model Year:** Tahun produksi dari model mobil tersebut.
- **Origin:** Negara atau wilayah asal dari mobil.

Key Components

Strategy to Reach Our Goals




Describing Data

kita menggunakan `df.info()` untuk mendapatkan jumlah total baris, nama kolom, jumlah non-null (missing value) untuk tiap kolom, dan tipe data tiap kolom



Exploratory Data Analysis

mencari statistika deskriptif dari tiap kolom numerik menggunakan `df.describe()`, cek outliers, missing value, dan distribusi data nya serta cek juga apakah ada duplikasi data.



Feature Engineering


Melakukan encoding untuk data kategorik lalu gunakan `drop_first = True` untuk menghindari dummy variabel untuk mencegah multikolinearitas, karena korelasi antar variabel prediktor tinggi, solusinya adalah membuat interaksi antara fitur yang berkorelasi tinggi, lalu kami juga mentransformasi data untuk meningkatkan akurasi model, mengurangi dampak outlier, dan menangani distribusi data tidak normal



Modelling + Evaluation

Model yang digunakan adalah regresi linear, dimana regresi linear sendiri memiliki karakteristik memprediksi variabel kontinu, mengasumsikan hubungan linear antara fitur dan target, mudah dijelaskan karena koefisien menunjukkan seberapa besar pengaruh pada prediksi, cara mengevaluasi model nya bisa menggunakan Mean Square Error (MSE), Root Mean Squared Error (RMSE), Mean Absolute Error (MAE), dan nilai R-squared (R^2)

DATA PREPARATION & EDA



Pengumpulan Data

- Menggunakan library pandas untuk membaca dan mengelola data.
- File Automobiles.csv diunduh dari Google Drive dengan perintah wget langsung melalui link publik.
- File berhasil diunduh dan dibaca menggunakan pd.read_csv().
- Dataset berisi 398 baris data mobil dan 9 kolom informasi seperti:
 - name, mpg (efisiensi bahan bakar), cylinders, horsepower, weight, dll.

SOURCE:

LINK DATASET

LINK GOOGLE COLAB

```
[75] import pandas as pd

[76] !wget --no-check-certificate 'https://docs.google.com/uc?export=download&id=10gP6EIkrVkvPr3TwQwAFBVf-MyPDZHY' -O 'Automobiles.csv'

--2025-04-17 13:09:36-- https://docs.google.com/uc?export=download&id=10gP6EIkrVkvPr3TwQwAFBVf-MyPDZHY
Resolving docs.google.com (docs.google.com)... 173.194.193.102, 173.194.193.138, 173.194.193.113, ...
Connecting to docs.google.com (docs.google.com)|173.194.193.102|:443... connected.
HTTP request sent, awaiting response... 303 See Other
Location: https://drive.usercontent.google.com/download?id=10gP6EIkrVkvPr3TwQwAFBVf-MyPDZHY&export=download [following]
--2025-04-17 13:09:37-- https://drive.usercontent.google.com/download?id=10gP6EIkrVkvPr3TwQwAFBVf-MyPDZHY&export=download
Resolving drive.usercontent.google.com (drive.usercontent.google.com)... 74.125.132.132, 2607:f8b0:4001:c00::84
Connecting to drive.usercontent.google.com (drive.usercontent.google.com)|74.125.132.132|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 19285 (19K) [application/octet-stream]
Saving to: 'Automobiles.csv'

Automobiles.csv  100%[=====] 18.83K  --.-KB/s  in 0s

2025-04-17 13:09:39 (37.6 MB/s) - 'Automobiles.csv' saved [19285/19285]
```

```
df = pd.read_csv("Automobiles.csv", encoding = 'utf-8')
df
```

	name	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	origin
0	chevrolet chevelle malibu	18.0	8	307.0	130.0	3504	12.0	70	usa
1	buick skylark 320	15.0	8	350.0	165.0	3693	11.5	70	usa
2	plymouth satellite	18.0	8	318.0	150.0	3436	11.0	70	usa
3	amc rebel sst	16.0	8	304.0	150.0	3433	12.0	70	usa
4	ford torino	17.0	8	302.0	140.0	3449	10.5	70	usa
...	...	...	...	...	...	...	...	...	...
393	ford mustang gl	27.0	4	140.0	86.0	2790	15.6	82	usa
394	vw pickup	44.0	4	97.0	52.0	2130	24.6	82	europa
395	dodge rampage	32.0	4	135.0	84.0	2295	11.6	82	usa
396	ford ranger	28.0	4	120.0	79.0	2625	18.6	82	usa

Identifikasi Fitur (Kolom)

- Pemeriksaan awal dataset dilakukan dengan `df.info()` dan `df.columns`.
- Dataset terdiri dari:
 - 398 entri, tanpa nilai kosong (semua kolom lengkap).
 - Total 9 kolom: 4 bertipe `float64`, 3 bertipe `int64`, dan 2 bertipe `object`.
- Tipe data memberikan gambaran awal bagaimana data akan diproses:
 - `float64`: untuk nilai kontinu seperti `mpg`, `displacement`, `horsepower`, dll.
 - `int64`: untuk data numerik diskrit seperti `cylinders` dan `model_year`.
 - `object`: untuk data kategorikal seperti `name` dan `origin`.

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 398 entries, 0 to 397
Data columns (total 9 columns):
 #   Column          Non-Null Count  Dtype  
---  -
 0   name            398 non-null   object  
 1   mpg             398 non-null   float64 
 2   cylinders       398 non-null   int64   
 3   displacement    398 non-null   float64 
 4   horsepower      392 non-null   float64 
 5   weight         398 non-null   int64   
 6   acceleration    398 non-null   float64 
 7   model_year      398 non-null   int64   
 8   origin          398 non-null   object  
dtypes: float64(4), int64(3), object(2)
memory usage: 28.1+ KB

[79] df.columns

Index(['name', 'mpg', 'cylinders', 'displacement', 'horsepower', 'weight',
      'acceleration', 'model_year', 'origin'],
      dtype='object')
```





Deskripsi Data

- `df.describe()` digunakan untuk melihat ringkasan statistik dari kolom numerik dalam dataset.

INSIGHTS

- Efisiensi Bahan Bakar (mpg):
 - Rata-rata: 23.5 mpg, dengan rentang dari 9 hingga 46.6 mpg.
- Tenaga Mesin (horsepower):
 - Rata-rata: 104 HP, maksimum: 230 HP, terdapat variasi yang besar (std: 38.49).
- Berat Mobil (weight):
 - Rata-rata: 2970 lbs, dengan berat terendah 1613 lbs dan tertinggi 5140 lbs.
- Tahun Produksi (model_year):
 - Tersebar dari tahun 70 sampai 82.





```
df.describe()
```

	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year
count	398.000000	398.000000	398.000000	392.000000	398.000000	398.000000	398.000000
mean	23.514573	5.454774	193.425879	104.469388	2970.424823	15.568090	76.010050
std	7.815984	1.701004	104.269838	38.491160	846.841774	2.757689	3.897627
min	9.000000	3.000000	68.000000	46.000000	1613.000000	8.000000	70.000000
25%	17.500000	4.000000	104.250000	75.000000	2223.750000	13.825000	73.000000
50%	23.000000	4.000000	148.500000	93.500000	2803.500000	15.500000	76.000000
75%	29.000000	8.000000	262.000000	126.000000	3808.000000	17.175000	79.000000
max	46.600000	8.000000	455.000000	230.000000	5140.000000	24.800000	82.000000

Deskripsi Data

- Memiliki 398 baris dan 9 kolom
- Memiliki Missing Value pada horsepower dan terdapat outliers di beberapa variabel
- skew yang lumayan ekstrim terdapat di variabel 'displacement', 'horsepower', dan 'weight'
- dari 9 variabel 7 variabel merupakan variabel kontinu dan 2 Variabel merupakan Variabel Kategorik
- Variabel target adalah 'mpg'



```
df.dtypes
```

	0
name	object
mpg	float64
cylinders	int64
displacement	float64
horsepower	float64
weight	int64
acceleration	float64
model_year	int64
origin	object

dtype: object

```
df.isnull().sum()
```

	0
name	0
mpg	0
cylinders	0
displacement	0
horsepower	6
weight	0
acceleration	0
model_year	0
origin	0

dtype: int64

Pemeriksaan Missing Value

- Pengecekan dilakukan untuk mengetahui apakah ada nilai yang hilang pada dataset.
- Hasilnya: hanya kolom horsepower yang memiliki 6 missing values.
- Kolom lainnya lengkap tanpa data yang hilang.

```
missing_values = df.isnull().sum()  
print(missing_values)
```

```
name      0  
mpg       0  
cylinders  0  
displacement  0  
horsepower  6  
weight    0  
acceleration  0  
model_year  0  
origin    0  
dtype: int64
```


Ya, terdapat 6 missing values pada kolom horsepower.

Pendeteksian Outliers

- Kode menggunakan library Seaborn dan Matplotlib untuk membuat boxplot horizontal dari fitur numerik.
- Boxplot membantu mengidentifikasi outlier atau nilai-nilai ekstrem yang berada di luar rentang normal.
- Semua fitur bertipe numerik dipilih secara otomatis menggunakan `select_dtypes(include=['number'])`.
- Judul dan label sumbu dibuat lebih jelas dan readable, serta rotasi label sumbu Y diatur agar lebih mudah dibaca.
- Hasil visualisasi ini penting untuk proses pembersihan data (data cleaning).

```
import matplotlib.pyplot as plt
import seaborn as sns

fig, ax = plt.subplots(figsize=(12, 8))
sns.boxplot(data=df.select_dtypes(include=['number']), ax=ax, orient="h")
ax.set_title("Boxplot untuk Mendeteksi Outlier", fontsize=16)
ax.set_xlabel("Nilai", fontsize=12)
ax.set_ylabel("Fitur", fontsize=12)
plt.xticks(rotation=45, ha='right')
plt.show()
```



Berdasarkan visualisasi boxplot, dapat disimpulkan bahwa terdapat outlier pada beberapa fitur dalam dataset.

Pengecekan Data Duplikat


- Digunakan kode: `df.duplicated().sum()`
- Mengecek apakah ada baris yang identik di seluruh kolom
- Hasil: 0 baris duplikat ditemukan

```
data_duplikat = df.duplicated().sum()
print(f"Jumlah data yang duplikat: {data_duplikat}")
```


Jumlah data yang duplikat: 0

Univariate, Bivariate, dan Multivariate


- Univariate berfokus pada satu variabel untuk memahami pola distribusinya.
- Bivariate menjadi sebagai Insight awal terhadap potensi korelasi antar variabel.
- Multivariate, yakni Heatmap korelasi yang digunakan untuk mengamati interaksi antar seluruh fitur



Univariate




Bivariate



Multivariate

DATA PREPROCESSING




Feature Engineering

Encoding

Menggunakan metode One-Hot Encoder pada variabel 'cylinders' dan Variabel 'origin'

cylinders_4	cylinders_5	cylinders_6	cylinders_8	origin_japan	origin_usa
False	False	False	True	False	True
False	False	False	True	False	True
False	False	False	True	False	True
False	False	False	True	False	True
False	False	False	True	False	True
...	...	...	...	...	...
True	False	False	False	False	True
True	False	False	False	False	False
True	False	False	False	False	True
True	False	False	False	False	True
True	False	False	False	False	True

MODEL BUILDING



Model Building

Challenges - 40%

- Multicollinearity antar fitur
- Data tidak bersih (missing & outlier)
- Skala fitur berbeda
- Risiko overfitting



Strategy - 30%

- Cek korelasi & drop fitur terkait
- Imputasi & normalisasi data
- Cross-validation




Solution - 30%

- melakukan pengisian missing value dengan median
- scaling menggunakan RobustScaler yang tahan terhadap outlier
- membuat interaksi antar fitur yang berkorelasi tinggi
- Evaluasi pakai RMSE, MAE, dan R^2
- Melakukan Evaluasi model dengan Cross Validation untuk melihat underfitting/Overfitting




MODEL EVALUATION



Model Evaluation

Metrik	Nilai	Interpretasi
MSE	5.9687	Rata-rata kuadrat kesalahan prediksi. Nilai ini menunjukkan penalti terhadap kesalahan besar. Semakin kecil, semakin baik.
RMSE	2.4431	Akar dari MSE. Artinya secara umum, model memiliki kesalahan prediksi sekitar 2.44 MPG , cukup kecil dan bagus.
R^2	0.8890	Model mampu menjelaskan 88.9% variasi dalam data target (MPG). Ini menunjukkan model sudah sangat baik.
MAE	1.7940	Rata-rata kesalahan absolut model adalah 1.79 MPG , yang artinya model cukup akurat dan tidak terlalu jauh dari nilai sebenarnya.


MODEL CONCLUSION





Model Conclusion

Residual Plot



Model regresi yang dikembangkan menunjukkan performa akurasi yang tinggi dalam memprediksi nilai MPG. Model ini terbukti andal dan layak digunakan dalam berbagai skenario prediktif, seperti sistem rekomendasi mobil hemat bahan bakar, evaluasi efisiensi kendaraan, hingga simulasi konsumsi bahan bakar berdasarkan spesifikasi teknis mobil.

Model Conclusion

Model yang Digunakan

Linear Regression — cocok untuk prediksi nilai kontinu seperti MPG.

Performa Model

- MAE: 1.79
- RMSE & R^2 menunjukkan performa prediksi yang baik.
- Cenderung underfitting rendah, mampu mengenali pola data baru.


Insight Utama

- Berat mobil berkorelasi negatif terhadap efisiensi bahan bakar (MPG).
- Jumlah silinder tinggi = konsumsi BBM lebih boros.

Potensi Penggunaan

- Digunakan sebagai sistem rekomendasi mobil hemat BBM.
- Membantu pembeli memilih mobil berdasarkan efisiensi.
- Bisa dikembangkan untuk evaluasi kebijakan kendaraan ramah lingkungan.

MODEL USABILITY



Model Usability

Model ini tidak hanya memberikan hasil yang cukup akurat (MAE: 1,7940), tetapi juga mudah dipahami, efisien secara komputasi, dan siap untuk digunakan secara langsung dalam memprediksi penggunaan MPG Mobil di Masa depan. Model kami sedikit lebih baik dalam data test, artinya jika diberikan data baru model kita cukup mampu memahami pola umum dan memprediksi data baru dengan lebih baik. Model ini sangat berguna untuk memprediksi penggunaan konsumsi bahan bakar.

MSE: 5.9687

RMSE: 2.4431


R^2 Score: 0.8890

MAE: 1.7940

R^2 Train: 0.8737

R^2 Test : 0.8890

Data Analysis



Conclusion Gathered from dataset.

1. Hubungan Antara Berat Mobil dan MPG


Terdapat korelasi negatif antara berat mobil (weight) dengan konsumsi bahan bakar. Semakin berat mobil, umumnya semakin rendah nilai MPG-nya.

2. Peran Jumlah Silinder (Cylinders)

Mobil dengan jumlah silinder lebih banyak cenderung memiliki konsumsi bahan bakar yang lebih boros, meskipun memiliki tenaga lebih besar.

3. Distribusi MPG

Nilai MPG cenderung menyebar di kisaran 10–45, dengan puncak distribusi di antara 20–30 MPG, menunjukkan sebagian besar kendaraan berada pada level efisiensi menengah.



Questions? Reactions?

Feel free to get in touch with us.